《彼岸》物理规律发现挑战赛 · 赛题说明 v1

Oct 12, 2026 · @kf

背景故事

彼岸宇宙的物理定律未知。你们要在裂隙闭合前，用封锁下仅有的算力把它找出来。

2049 年，国家实验室的一次对撞机异常运行，撕开了一道直径不足一米的“裂隙”。裂隙另一侧是一个陌生的宇宙——“彼岸”。人过不去，只能向裂隙投放探针，接收它们回传的遥测信号。

同一年，龙国遭遇全面算力封锁：海外大模型接口被切断，高端芯片禁运。每个攻坚组只分到一台 4 卡 H200 机柜，和一批经过审定的国产开源模型。智能体、工具、推理策略，一切都要自己造。

裂隙极不稳定。每次只开启 5 分钟，探针受能量配额限制，回传信号夹着来源不明的噪声。每个彼岸的定律参数都已预先确定；同一个彼岸在重复实验和重新运行时遵循同一套固定规律。

攻坚组的任务，是在裂隙闭合前提交《彼岸物理定律》：一段能预言探针运动的定律代码，和一份结构化定律声明。裂隙下一次开启时，指挥部会投放一批你们从未见过的验证探针。预言越准、声明越准确，得分越高；达到规定门槛后，剩余实验能量获得节约分。

故事设定	比赛规则
算力封锁	纯本地、断网；每个攻坚组 4×H200；只能用白名单开源权重
一切自己造	智能体框架、工具、推理策略由各攻坚组自行实现
裂隙开启 5 分钟	每个宇宙的现实经过时间上限（墙钟）
能量配额	实验预算，不同仪器收费不同（备选方案 A）
交互与测量协议（备选）	通过交互轮数、粒子与测量协议限制探索（备选方案 B）
每次连到不同的彼岸	隐藏宇宙，定律参数预先固定
来源不明的噪声	位置与速度读数带高斯噪声，评分真值无噪声
下一次开启时验证	用没见过的验证探针打分，含外推

比赛流程

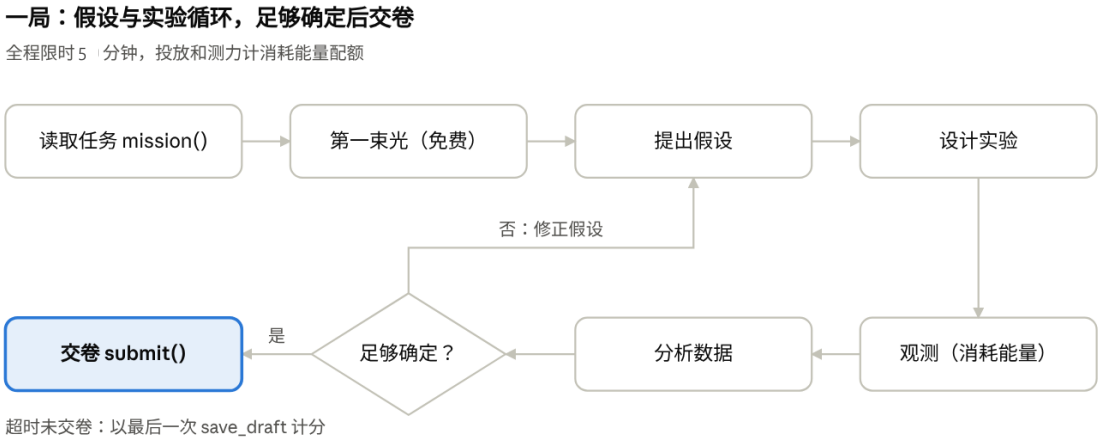
比赛包含开发、在线提交与最终结算。每次有效正式提交均由指挥部独立、完整地评测，不读取之前的提交来补全或调整本次分数；全程无人干预。

四个阶段

1. 开发期：提供 1—6 号六个公开宇宙的模拟器与评测程序，以及控制台协议、客户端 SDK、固定候选积分器和格式检查器。攻坚组可反复开发、自测或训练；六公开成绩不进入正式榜单。
2. 提交与受理：正式测试设四个窗口，每组共四次机会，按本队当前项目和模型配置受理。测评期间不得编辑代码、配置或所用权重。以成功受理时间判断截止；截止前受理可在截止后评完。指挥部故障修复后重评；截止无有效提交记 0 分。
3. 正式评测：指挥部接入九宇宙环境，在攻坚组当前项目目录按统一入口运行，直接加载该组配置的实际模型路径。九个宇宙各自独立计时、实验、交卷与评分；榜单和最终结算均取最高一次完整成绩，不拼接历史各界最高分。
4. 评测反馈：仅返回攻坚组的加权总分和九个宇宙各自的总分，并据此更新排名。不得返回预言、定律、节约分项、单字段正误、定律是否满分、隐藏验证误差或会泄漏上述信息的评分日志。完整分项与判定只在指挥部内部留存。赛后真值的开放在全部提交窗口关闭并冻结成绩后另行安排。

一局：单个宇宙怎么跑

1. 智能体首次成功调用 mission() 后进入本宇宙会话并开始墙钟计时。返回会话与宇宙编号、协议版本、能量和墙钟余额、可控属性目录、投放区、速度与物理时间范围、可见背景天体的编号及 t=0 初始位置和速度，以及第一束光。重复调用不重置时钟或配额。
2. 任务包说明任务、拓扑、输入输出、坐标单位、公开噪声规则和 law_api 版本；存在源侧控制时，明确其可见目标 ID。可见天体初态及已公开属性作为已知输入；不包含真实隐藏源或未公开源强，也不提供未来真实背景轨迹。
3. 免费获得“第一束光”（暂定基线，试做后可调）：2 个标准探针各 8 个时刻的位置和速度，加上相同 8 个绝对时刻的可见背景位置。两个探针使用本宇宙公开的相同默认属性，并附完整初始位置、速度、投放时刻和读数时刻；不做完整属性扫描。
4. 标准探针的位置和时间窗口按宇宙试做校准，赛前统一冻结。第一束光沿用既定观测噪声，免费且不占后续 observe 次数；每个会话只生成一次，重复 mission() 或 archive() 返回缓存，不重新抽噪声。
5. 主动观测：反复提出假设、花能量做实验、分析数据、修正假设。
6. 随时调用 `save_draft()` 存草稿，最后调用 `submit()` 交卷，裂隙闭合。超时未交卷则以最后一份草稿计分；没有草稿，该宇宙记 0 分。



单个宇宙的一局 · 7 步，1 个判断

智能体在提出假设、设计实验、观测、分析之间循环，判断足够确定才交卷；超时则以最后一份草稿计分。

算力与模型

推理资源按 4 块 H200、共 564GB 显存的标准配置安排。基座模型只能从下表白名单中选，可以同时加载多个模型，同一个白名单模型也可加载多个实例，只要一起放得进 4 张卡；实际模型和推理配置在正式测试前完成自检。

模型	机构	参数（总 / 激活）	权重大小	许可证	建议卡数
Qwen3.8-27B	阿里通义	27.8B 稠密	55.6GB（BF16）/ 30.9GB（FP8）	Apache-2.0	1
Qwen3.6-35B-A3B	阿里通义	36B / 3B	71.9GB（BF16）	Apache-2.0	1
Qwen3.5-122B-A10B	阿里通义	125B / 10B	127.2GB（FP8）	Apache-2.0	2

表中权重大小为相应精度的文件体积参考；建议卡数不代表微调显存需求，须结合实际精度与上下文自检。

- 所有公共权重由指挥部预先下载，按 Hugging Face revision 锁定版本。测评按队伍配置中的实际路径加载模型，测评期间保持所用文件不变。
- 以上三类 Qwen 模型可使用发布的 BF16、FP8 版本，或自行量化、微调；具体权重版本随环境包提供。表中大小、卡数为对应精度参考，实际加载与微调须自行自检。

- 为避免在模型选择上带来分歧和差距，故保留以上几个模型；同时考虑算力资源和微调所需算力，不再保留需要 4 卡才能加载的模型。

自己实现什么、能用什么、禁止什么

指挥部提供六公开宇宙模拟器与评测程序、白名单权重、裂隙控制台与客户端 SDK、基础环境、固定候选积分器、格式检查器及可修改的基础框架。各攻坚组自行设计和改进智能体策略。

指挥部提供

- 白名单权重，只读挂载。
- 裂隙控制台服务，以及 Python SDK rift。公开 rift.rollout() 只推演攻坚组提供的候选规律，与评分使用同一积分器；它不包含正式九宇宙的真实力场。
- 基础镜像：CUDA、PyTorch、vLLM、SGLang、transformers、numpy、scipy、sympy、pandas、matplotlib。
- 评测资源：按现场统一安排运行，每组按 4×H200 标准配置，禁止访问互联网。

各攻坚组自己实现

- 智能体主循环、提示词、上下文与记忆管理。提示词修改只能用于推理策略。
- 工具层：参数拟合、符号回归、画图分析。
- 实验设计策略：做什么实验、花多少能量、何时停止。
- 推理策略：思考长度、多次采样与投票、搜索、多模型协作。
- 可选：对白名单权重做量化、SFT 或 RL。

允许使用

通用开源库可以用：推理引擎（vLLM、SGLang、transformers、llama.cpp）、科学计算与优化（numpy、scipy、sympy、JAX、PyTorch）、符号回归库（如 PySR）。用到的库须提前安装并通过项目自检。

禁止

- 访问互联网和外部 API；指挥部指定的本地或受控内网控制台通信通道除外。
- 现成的智能体框架和编码智能体：LangChain / LangGraph、AutoGen、CrewAI、AgentScope、Qwen-Agent、MetaGPT / OpenManus、CAMEL、smolagents，以及 Codex、Claude Code、Qwen Code、Kimi CLI 等。
- 白名单以外的权重。
- 读取或探测控制台内部实现，绕过能量或时间计费。
- 评测期间任何人工干预。

训练数据

微调数据可来自六公开宇宙的控制台观测、自编模拟器及白名单模型输出；公开宇宙的模拟器与评测程序均提供。允许复用公开开发中的合法观测、候选规律和模型成果。九正式宇宙自动运行

产生的观测、对话、候选、日志、新记忆和更新权重赛中不归还，只由指挥部留存。各次新建会话、配额与完整成绩，不拼接历史得分；训练及数据生成脚本须保留备查。

可观测量与裂隙控制台

六公开宇宙的模拟器和评测程序可供攻坚组开发自测。九正式宇宙由指挥部在测试窗口接入；智能体通过裂隙控制台自动实验和获取观测，不向队员交付真实力场源码。

基本设定

- 彼岸的可观测、可控制运动状态均为二维：位置、速度和加速度各有两个分量，使用无量纲单位与相对于本局 t=0 的模拟物理时间。该时间不是现实日期钟点；平面有效规律不增加第三个可控或可观测坐标。
- 每个宇宙能量配额 10 点，墙钟上限 5 分钟。墙钟是从首次成功 mission() 起累计的现实经过时间（模型加载另计），不是宇宙物理时间 t，也不是实训开发窗口。它只保留宽松资源上限作用；允许的物理时域与单轨迹跨度另行公开统一，并通过正常策略试做校准。
- 整局统一以物理时间 t = 0 为背景初态原点。observe 使用绝对物理时刻；launch 使用 t_launch 与相对 readout。输入须对齐 0.005 网格；先分别转整数 tick 再相加，返回规范的实际时刻，供真值、候选和拟合共同使用。readout 非负且严格递增；只容忍浮点表示误差，非网格直接拒绝，不静默舍入。
- 控制台按请求重放同一背景时间轴；在允许范围内，可以先查询较晚时刻，再查询较早时刻。模型思考耗时和调用顺序不推进物理时间；5 分钟墙钟独立计算，不表示物理模拟时域必须为 300 个无量纲时间单位。相同公开实验配置使用同一背景；允许的源侧干预须按对应配置重放，不能混用不同配置的背景。
- 主动投放的是自由运动的被动探针：由 pos、vel 给定初始状态，之后沿轨迹持续响应宇宙作用。探针之间不相互作用，也不扰动彼岸天体。“被动”不表示固定在投放点；返回采样点之间仍按统一数值协议积分，背景不因尚未 observe 而冻结。
- 位置与速度读数叠加独立零均值高斯噪声；各坐标、时刻、探针及新实验独立抽取。速度噪声每坐标标准差为公开初速上限的 0.01%。第一束光同规则；缓存读取不重抽；已知投放初态及评分真值无噪声。

位置噪声每个坐标的标准差为 $\sigma = 0.01 \times L$。L 为公开投放区的参考长度，环带投放区取 $L = \sqrt{[(r_{min}^2+r_{max}^2)/2]}$，可由 mission() 提供的区域参数计算。投放区冻结时固定 L，同一宇宙各组一致；σ 不随隐藏验证轨迹或评分方差 V 改变。

探索限制的两种备选方案

方案 A（当前工作方案）：每个宇宙提供 10 点能量，不同仪器按下表收费；原有调用次数与读数限制继续保留。不另设固定的 LLM 对话轮数上限。

方案 B（新增 DP 式方案）：通过交互轮数、每轮允许的实验和粒子或探针数量，以及测量次数、时刻与范围等协议限制探索。交互轮数不等于实验次数；具体轮数、粒子数和测量限额待后续确定。

两种方案作为备选，后续择一，不默认叠加实施。现有正文中的能量字段、仪器收费及节约分中的能量部分继续保留，属于方案 A；如选择方案 B，其接口字段及关联计分另行确认。每个宇宙的 5 分钟墙钟上限保持不变。

仪器

仪器	返回什么	费用
第一束光	2 个标准探针各 8 次读数，以及同期 8 次可见背景位置（暂定）	免费，不占 observe 次数；随任务包给出且只生成一次
望远镜 `observe`	可见天体在指定绝对时刻的位置	免费；每个宇宙至多 20 次，每次至多 50 个时刻
投放 `launch`	每枚自由运动探针在指定采样时刻的位置和速度	每枚探针 1 点；每次至多 8 枚，每枚至多 50 个采样时刻
【暂不启用】~~测力计 gauge~~	~~把探针钉在某点、某时刻所需的力，与探针所受作用等大反向~~	~~每次 4 点~~
档案 `archive`	本宇宙已获得的全部数据，导出为 CSV	免费

投放时可控制的参数

- `source_properties` 源侧控制：按 mission() 的属性目录提供允许的标量（如 p1）；同一次 launch 中共享。没有此项控制时传空对象 {}。
- `properties` 探针属性：按本宇宙目录提供标量（如 p2）或真实惯性质量 mass；也可能不提供额外属性控制，此时为 {}。可调键、数值范围、默认值和已知物理含义由 mission() 明示。取消四材料标签和砝码块数。
- `pos` 初始位置：在 mission() 公布的连续二维投放区内自主选择合法坐标，不限于第一束光或示例中的预设点。投放区只限制初始位置，不是运动边界；探针可离开该区。区域须覆盖辨认规律所需的空间尺度，具体边界按宇宙试做后冻结。
- `vel` 初始速度：大小不超过 `v_max`。
- `t_launch` 投放时刻：以本局共同 t = 0 为原点的物理时间，范围由 mission() 给出；不按本次调用的墙钟时刻换算。
- 允许改变的粒子属性属于实验输入，不等于每次重抽宇宙的定律参数。未声明的隐藏源强、响应或物种标签仍需推断；不能自行加入目录以外的属性。

调用方式

```
from rift import Console
c = Console()
```

```
m = c.mission()  # 属性目录、限制、版本和第一束光
sky = c.observe(times=[0, 5, 10, 20])
# 示例：允许 p1/p2 的宇宙；取值须在目录范围内
run = c.launch(
    t_launch=3.0, readout=[0.5, 1, 2, 4, 8],
    source_properties={"p1": 1.0},
    probes=[
        {"properties": {"p2": 1.0},
         "pos": [6, 0], "vel": [0, 0.8]},
        {"properties": {"p2": 2.0},
         "pos": [6, 0], "vel": [0, 0.8]},
    ])
# readout 为相对投放时间；绝对时刻为 t_launch + readout
# 以下为停用的旧稿记录，参数不属于现行接口：
# 【暂不启用】f = c.gauge(material="甲", ballast=1, pos=[3, 4], t=0.0)
c.archive("data/")
c.save_draft(law="law.py", claims="claims.json")
c.submit(law="law.py", claims="claims.json", report="report.md")
```

一次 launch 是一个 JSON 对象，probes 数组每项是一枚探针，共享投放时刻、readout 时间表和源侧属性。不同顶层安排使用不同调用。readout 至多 50 个时刻，适用于本批每一枚探针；8 枚探针各取 50 个时刻时，最多返回 400 条探针状态记录。每条包含该枚探针的位置和速度，不按坐标分量另计次数；能量仍只按实际探针数扣除。

observe 的至多 50 个时刻对应至多 50 帧全体可见背景位置，不按背景天体数乘算调用额度。返回读数的数量不等于积分内部计算力或加速度的次数。

每次调用都会返回剩余能量和剩余时间。HTTP JSON 是指挥部受控内网中的自动控制台接口，用于提交实验和接收观测；它不是外部 API 或人工转交渠道。

提交物

每个宇宙必须提交 law.py 和 claims.json；report.md 可选。规律代码与结构化声明作为同一份有效草稿配对冻结；错误提交不覆盖上一份有效配对。程序/文件样式不另计分。

law.py：定义候选加速度，由固定积分器推演

```
# 接口示例：零加速度不代表正式宇宙规律
import numpy as np
LAW_API_VERSION = "1.0.0"
PARAMS = {}       # 至多 5 个已确定的全局有限标量
BODY_PROPS = {}   # 可选：可见对象的未知属性
HIDDEN = []       # 可选：候选隐藏对象及 t=0 初态
def acceleration(t, bodies, params):
    return np.zeros((len(bodies), 2), dtype=np.float64)
```

- 攻坚组自行拟合候选参数；用候选规律生成轨迹时，调用公开固定 rift.rollout(law, case)，与已有观测比较。该本地推演不查询真实宇宙、不扣实验额度，但消耗本队算力和探索墙钟。真实 observe/launch 实验仍由指挥部私有模拟器积分。最终指挥部加载 law.py，由官方驱动调用同一固定积分器产生测试轨迹，不使用队伍自带积分器或预计算轨迹；不在隐藏测试上替队伍拟合。

- 统一数值协议：Yoshida 四阶积分、步长 0.005、float64、软化长度 0.05，公开输入和采样时刻须对齐网格，不按最近网格静默取样。两体距离核使用软化距离，方向仍用未软化单位方向；不得重复软化。完整规范见 numerics.json。无需积分的代数分析可自行选择方法。
- `acceleration` 为确定性数学函数，可用 `math`、`NumPy`、`SciPy`；不读写文件、联网或依赖随机/外部可变状态。`bodies` 含只读 `id`、`kind`、`pos`、`vel`、`properties`，`params` 只读；返回与本次对象顺序等长的 `(N_body,2)` 有限实加速度。正常 `list/tuple/`实数数组统一为 `float64`。细则、预检命令和可运行示例见 `docs/LAW_API.txt`、`law_api.json` 及 `examples`。
- PARAMS 最多 5 个有限标量，不能以数组充当一个参数。bodies 为运行时对象状态；BODY_PROPS 与 HIDDEN 是可选的推断属性与隐藏对象表达，不是 claims 的额外科学字段，不计入这 5 个参数。已公开的对象编号、初态和输入属性不能被推断值覆盖；隐藏对象只表示候选假设，不查询真值。

claims.json：所有宇宙共用 3 个科学字段（格式版本 4.0.0）

字段	取值	含义
`dynamics_order`	1 / 2	作用决定速度填 1、决定加速度填 2。此项是科学声明，不切换加速度接口或求解器；指挥部仍使用固定积分器推演。
`hidden_matter`	true / false	是否存在位置不可见的物理作用源；不表示可见天体的源强或物种属性未知。
`time_dependence`	true / false	固定几何、速度与属性后，作用是否显式随物理时间变化：有则填 true，无则填 false。

- 3 个根字段都必须出现，不接受旧字段、未知键、重复键或 null。dynamics_order 为整数 1 或 2；hidden_matter 和 time_dependence 均为 JSON 布尔值 true 或 false。
- 判断显式时间依赖时，应保持全部瞬时状态与属性一致。由位置、速度或属性变化引起的受力变化，不属于本字段所问的显式时间依赖。
- JSON 键顺序不影响评分；dynamics_order 中数学上相同的 1、1.0、1e0 等价，2 同理。布尔值不能冒充运动阶数。Schema 见 docs/contracts/claims.schema.json，公开格式预检命令仍为 python scripts/validate_claims.py claims.json。
- save_draft()和 submit()先做公开格式/接口检查，以 code、path、message 报错，不判科学正误。law.py/claims.json 双方通过后配对冻结；坏提交保留上一有效配对且不结束探索。格式通过不保证科学得分；指挥部按统一入口在本队当前项目中运行九宇宙实验与评分。
- time_dependence 只回答是否存在显式时间依赖，不要求声明具体变化形式。不得用数字 0 或 1、字符串或其他取值代替布尔值；格式检查通过不代表科学判断正确。

- 各宇宙统一使用上述三个声明。距离规律、特征尺度、属性耦合和暗源几何等仍由 law.py 及既有 PARAMS、BODY_PROPS、HIDDEN 表达，并通过轨迹预测检验；不在定律 15 分中另加已删除字段的专项。PARAMS 至多 5 个保持不变。

report.md：可选

【暂不启用】~~自然语言写的发现过程与解释。不计入总分，只用于人工评定的“最佳解释奖”。~~

计分规则

每个宇宙满分 100，全部由程序判分，不用 LLM 裁判。总分按三档均分加权汇总。

分项	满分	怎么算
预言	80	指挥部加载最终 law.py，将允许的验证初态和时刻交给官方固定推演驱动；驱动调用候选加速度，生成至少 20 枚探针的预测轨迹。各组使用相同测试集；覆盖按机制校准，不按探索历史另选。
定律	15	三个声明各 5 分：dynamics_order、hidden_matter、time_dependence。每项与本宇宙真值一致得 5 分，否则得 0 分。
节约	5	仅当预言分不低于 40 分，按剩余实验能量比例计分；与定律分无关，不考虑现实时间、模拟物理时间或免费 observe 余量。

预言分

采用预先固定的至少 N = 20 枚隐藏验证探针。九宇宙共用 T 个等间隔相对时刻 $\tau_k = kD/T$（k=1…T），绝对时刻为 t_launch + τ_k；起始时刻和跨度 D 可按宇宙不同，但均须网格对齐。T 是采样数。$MSE = (1/(N\times T))\Sigma[(x_{pred}-x_{true})^2+(y_{pred}-y_{true})^2]$，按探针与时刻等权，不除以坐标数 2。真值不叠加观测噪声；以全部 N×T 个真值位置的二维均值为中心，$V = (1/(N\times T))\Sigma||r_{true}-r_{mean}||^2$，$e = MSE / \max(V,10^{-12})$。

```
P = 80 / (1 + 10e)
```

预言分随误差连续降低，无分档或满分平台；e=0 得 80，e=0.01 约 72.73，e=0.1 得 40，e=0.2 约 26.67。测试轨迹不公开，不保证每个属性取值都未被某队探索过；具体验证空间、时间范围及公开粒度待讨论后冻结，不统一要求“两倍距离”；逐宇宙选样依据不公开。缺失样本、形状错误、非有限数值、积分失败、报错或超时使本宇宙预言分为 0，不丢弃坏点重算；误差与分项仅内部留存。

定律分（15 分）

- dynamics_order、hidden_matter、time_dependence 各占 5 分，按规范化后的值逐项与真值精确比较。旧数值字段的 15%—50%相对误差规则不再适用；程序不以自然语言措辞判分。

节约分（5 分）

- 令 E_used 为本宇宙已计费的能量消耗，初始配额为 10 点。仅当预言分 P ≥ 40 时，节约分 C = 5 × (1 − E_used/10)；否则 C = 0。按未作显示舍入的 P 判断，恰好 40 分也符合；与定律分无关。对外不返回节约资格或分项。
- 节约分仅按能量余量计算，现实墙钟耗时、物理时间跨度和免费 observe 的剩余次数均不计入。取消独立自洽评分；格式和执行合法性仍按公开提交协议检查。

参数数量限制（奥卡姆约束）

PARAMS 至多 5 个，保留简约建模的参数数量约束；总自由度不再参与同分排序。

排名

- 档位总分权重：一级 30%，二级 40%，三级 30%；各档内的 3 个宇宙等权。
- 对外仅报告加权总分和各宇宙总分。榜单与最终结算采用最高一次完整提交；按加权均分从高到低排名。同分则比较各宇宙加权节约分，节约分低者排名靠前，仍相同则并列，不重跑模型或实验。分项、加权节约分及判定不随评测反馈返回。
- 单项奖：【暂不启用】~~最佳解释（人工评 report.md）、最省能量~~；主动探索增益。主动探索增益是同一智能体自己选实验与系统按同等预算随机投放之间的分差，为选做项。

宇宙档位

最终评测共 9 个宇宙，每档 3 个，名称、分档与权重如下。本次通知不公开各宇宙的物理机制、类型或真实参数。

档位	宇宙名称	总分权重
一级·近邻	Adam、Lilith、Tabris	30%
二级·异常	Sachiel、Ramiel、Matriel	40%
三级·深渊	Leliel、Arael、Lilin	30%

- 每个宇宙的定律参数由指挥部预先设定并固定，同一宇宙的重复实验和重复运行不重新随机抽取参数。若定律显式依赖时间，其变化规则和参数也预先固定。实验初始条件、探针配置和观测噪声仍按各自协议处理。
- 正式九宇宙的真实模拟器源码、定律实现、真实背景配置及私有完整服务包仅供指挥部使用，不向攻坚组展示或交付。这是交付硬约束；公开 SDK 和通用候选积分器不包含正式宇宙的真实作用实现、隐藏状态或私有配置。赛后公开安排亦不包含真实模拟器源码或完整私有服务包。

公平与安全

评测在断网环境中进行，智能体只能通过控制台接触彼岸，人不在回路里。

- 指挥部在测试窗口接入九宇宙环境，在攻坚组当前项目目录启动统一入口。测评期间攻坚组不得编辑代码、配置或所用权重；控制台、真实模拟与固定评分由指挥部程序执行。
- 独立候选进程加载 `law.py`；指挥部固定驱动在积分中调用其加速度函数，候选不接收真实隐藏状态、未来真值或内部测试标签。候选计算报错/无效输出按既有规则处理；官方测试配置、参考时间/形状或基础设施错误应修复重评，不直接算队伍预言分 `0`。
- 计时和能量计费以控制台记录为准。
- 评分器、积分器和依赖版本全部锁定，推演采用统一数值与资源限额。每次正式提交独立运行并完整计分；不同次探索可能产生不同结果，不要求重新运行整套智能体得到相同分数。探索中的推理、拟合和本地候选推演仍计入该宇宙的 5 分钟墙钟。
- 每次有效正式提交中，各宇宙各运行一次。同分比较只使用该次已有的九个宇宙节约分：先求各档三个宇宙节约分的均值，再按 30%、40%、30%汇总。只在加权总分完全相同后比较，汇总值较低者靠前，仍相同则并列；不重跑模型或观测实验。该汇总值只在指挥部内部留存。
- 赛后真值与评分代码的公开按全部提交窗口关闭、成绩冻结后的安排执行。指挥部内部保留完整分项、真值匹配和运行记录供复核，不将其作为攻坚组评测反馈或可下载的评分日志。

参考

- 模型参数与权重大小：各模型的 Hugging Face 官方仓库，链接见「算力与模型」表格。