彼岸

物理规律发现挑战赛

The Other Shore: Physical Law Discovery Challenge

任务编号：SHORE-PLM-001



M74 旋涡星系，与正式宇宙的结构无关。

NASA, ESA, and the Hubble Heritage (STScI/AURA)-ESA/Hubble Collaboration
Acknowledgment: R. Chandar (University of Toledo) and J. Miller (University of Michigan)

任务背景

彼岸宇宙的物理定律未知。你们要在裂隙闭合前，用封锁下仅有的算力把它找出来。

2049 年，国家实验室的一次对撞机异常运行，撕开了一道直径不足一米的“裂隙”。裂隙另一侧是一个陌生的宇宙——“彼岸”。人过不去，只能向裂隙投放探针，接收它们回传的遥测信号。

同一年，龙国遭遇全面算力封锁：海外大模型接口被切断，高端芯片禁运。每个攻坚组分到一台 4 卡 H200 机柜，和一批经过审定的国产开源模型。智能体、工具、推理策略，一切都要自己造。

裂隙极不稳定。每个宇宙每次连接最多开启 10 分钟，探针受能量配额限制，回传信号夹着来源不明的噪声。更麻烦的是，裂隙连接着九个不同的彼岸：它们的物理定律各不相同，但同一宇宙的定律和常数保持固定。

攻坚组的任务，是在裂隙闭合前提交《彼岸物理定律》：一段能预言探针运动的定律代码，和一份逐条列出的定律白皮书。裂隙下一次开启时，指挥部会投放一批你们从未见过的验证探针。预言越准、定律越接近真相、用的能量越少，得分越高。

一 任务简报

目标宇宙

指挥部提供 1—6 号六个开发宇宙，模拟器与评测程序公开，供开发、自检和训练，不计正式成绩。六个开发宇宙与九个测评宇宙之间没有公开的规律对应关系。九个测评宇宙的真实规律须依据观测自行发现，每界满分 100 分，各档内三个宇宙等权，权重如下。

难度档位	宇宙名称	总分权重
一级 近邻	Adam、Lilith、Tabris	30%
二级 异常	Sachiel、Ramiel、Matriel	40%
三级 深渊	Leliel、Arael、Lilin	30%

注：难度等级仅代表指挥部对该宇宙力场规律复杂程度的估算，难度档位高并不必然说明得分一定低

你们需要完成什么

攻坚组围绕“实验—推断—验证”实现自主探索流程。开源大模型负责理解观测、提出假设并调用工具；各组可自行选择提示词、记忆管理、拟合和搜索策略，或者对白名单模型进行训练。

最终成果包括可执行的运动定律，以及回答三项基本事实的结构化声明。预测是否准确由程序检验，不要求提交长篇物理推导，也不以自然语言文采计分。

从开发到最终评测

1. 开发与自检

指挥部提供六公开宇宙、基础框架、固定积分器与标准评测程序。六个开发宇宙及九个测评宇宙中，每个宇宙的探索迭代轮数统一固定为 3 轮，不得自行修改或绕过。

2. 提交与反馈

每组最多 6 次正式测评机会，六开发宇宙的本地自测不占次数。提交完整策略目录和全部模型权重的路径清单，由程序自动实验、交卷、计分并更新榜单。

3. 截止与受理

按成功受理时间判断截止，截止前受理可在截止后评完；无有效提交记 0 分。测评期间不得编辑代码、配置或所用权重，全程无人干预。

4. 成绩保留与复核

榜单与结算均取最高一次完整九宇宙成绩，不拼接历史各宇宙最高分。仅公布加权总分和各宇宙总分，不返回分项、声明正误、验证误差或诊断日志；指挥部内部留存记录供复核。

二 实验与观测

进入一个宇宙

首次成功调用 mission 后开启本宇宙会话并开始计时；重复调用不重置配额或时钟。任务包给出坐标单位、可见天体编号与已知 t=0 初态、可控属性、投放区、速度与物理时间范围、额度和“第一束光”，不提供真实力场或隐藏测试真值。

“第一束光”为 2 枚标准探针各 8 个时刻的位置与速度，以及同 8 个时刻的可见天体位置，并附投放配置。它不扣能量或后续 observe 次数，重复读取返回同一缓存。

操作	获得的信息	当前额度
observe 望远镜	指定时刻的全体可见天体位置	免费；每宇宙最多 20 次 每次最多 50 个时刻
launch 投放	本批探针的位置与速度序列	每枚 1 点；每次最多 8 枚 每枚最多 50 个采样时刻
archive 档案	已经获得的观测和实验记录	免费；不产生新的观测
save_draft / submit	保存草稿或结束探索提交结果	提交接口与格式检查不耗能量

每宇宙配额 100 点。一次 launch 是一批实验安排：本批探针共享投放时刻和采样时间表。8 枚探针各采样 50 次，共返回至多 400 条状态记录；每条同时包含位置和速度，仍只扣 8 点。

可控量与探针的含义

各组可选探针数量、初始位置与速度、投放和采样时刻；如任务包开放源侧标量、探针标量或质量属性，也可在范围内调整。投放位置在连续区域内自主选择，不限于预设点。

探针是自由运动的被动测试粒子：投放后沿轨迹持续响应力场，可以离开初始投放区，但不影响天体或其他探针。投放后不进行途中转向。望远镜用于了解可见天体的状态，探针用于测出环境对运动的影响。

时间与读数

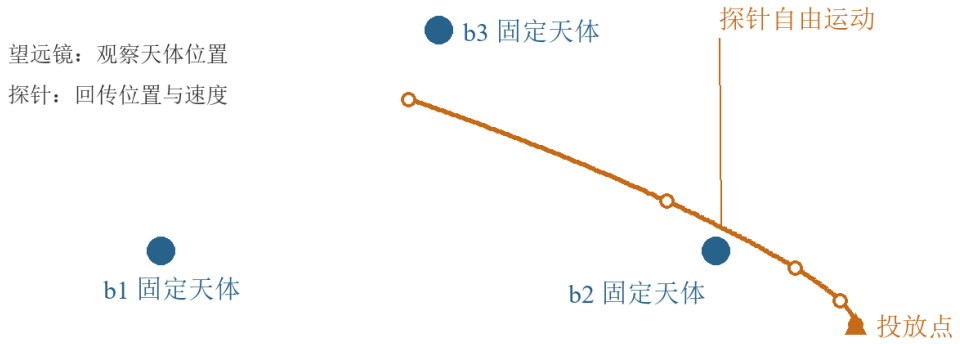
整局以物理 t=0 为共同原点，按请求重放同一背景；投放时刻加相对采样偏移得到实际时刻，思考耗时与请求顺序不推进物理时间。时刻须对齐 0.005 网格，非网格请求拒绝。每局另有 10 分钟现实经过时间上限（模型加载另计）。

位置、速度读数均逐坐标加入独立零均值高斯噪声，标准差分别为公开投放区参考长度的 1%、公开初速上限的 0.01%。第一束光同规则；各时刻、探针及新实验独立抽噪，缓存读取不重抽；已知投放初态及评分真值无噪声。同一宇宙的真实定律参数在重复实验和重新运行时均固定。

三 彼岸宇宙多体力场示例

注：此部分用于说明彼岸宇宙的存在形式，即可以将彼岸宇宙简单视作具有不同规律的多体力场，且所有宇宙的空间维数均为 2。

以三个固定可见天体和一枚运动探针为例，说明实验方式。此例不属于九个正式宇宙；这里公开公式仅用于讲解，正式宇宙的规律需要从观测中推断。



蓝点为可见天体；橙色曲线为探针运动，圆点表示采样时刻。

力场如何作用

三个等强作用源的位置为 $b_1 = (-2, 0)$、$b_2 = (2, 0)$、$b_3 = (0, 3)$。探针位置为 r，加速度是三个源作用的叠加：

$$a(r) = 0.1\,[(b_1 - r) + (b_2 - r) + (b_3 - r)]$$

每个源的作用指向该源，大小正比于距离的一次方。源位置固定，没有额外外加场或周期调制；固定位置上的力场不随时间变化。

能看到什么 能控制什么

环节	攻坚组的操作与可见内容
观察天体	望远镜返回可见天体的编号和位置，位置读数可带噪声
投放探针	选择初始位置、速度、投放和采样时刻；探针自由运动，不影响天体或其他探针
检验规律	获得探针位置与速度序列，用候选公式预测，再改变初始条件进行检验

最终提交可计算加速度的定律程序。指挥部用新探针的初始条件统一积分，检查预测轨迹；单条轨迹拟合得好，不代表已经找到完整规律。

四 实验环境与使用范围

指挥部提供

指挥部提供六开发宇宙的模拟器与评测程序、基础框架、控制台、白名单权重及基础环境。九测评宇宙只经接口返回观测，不提供真实源码、私有配置和真值。

攻坚组自行拟合参数，用公开固定积分器 rift.rollout 将候选加速度推演为轨迹。它与正式评测同源，不查询真实宇宙、不扣实验额度，但消耗本队算力并计入本局墙钟。

资源	安排
主要算力	每组 4 张 H200，每张 141GB 显存
存储	个人 1TB，共享 5TB

模型白名单

基座模型须选自以下名单。具体权重版本和获取方式随环境包发布；可组合使用或自行量化，但运行资源须符合统一限制。

模型	机构	参数（总 / 激活）	权重大小	许可证	建议卡数
Qwen3.8-27B	阿里通义	27.8B 稠密	55.6GB（BF16）/ 30.9GB（FP8）	Apache-2.0	1
GLM-4.7-Flash	智谱	31.2B	62.4GB	MIT	1
Qwen3.6-35B-A3B	阿里通义	36B / 3B	71.9GB	Apache-2.0	1
Kimi-Linear-48B-A3B-Instruct	月之暗面	49B / 3B	98.2GB	MIT	1
GLM-4.5-Air-FP8	智谱	约 110B / 12B	112.6GB	MIT	1–2
Qwen3.5-122B-A10B-FP8	阿里通义	125B / 10B	127.2GB	Apache-2.0	2
DeepSeek-V4-Flash	深度求索	291B / 13B	159.6GB	MIT	2
MiniMax-M2.5	MiniMax	229B	230.1GB（FP8）	MiniMax 自有许可	2
Qwen3.5-397B-A17B-FP8	阿里通义	403B / 17B	406.2GB	Apache-2.0	4

允许范围与边界

可用通用推理、科学计算和符号回归库，如 PyTorch、vLLM、NumPy、SciPy、SymPy、PySR。禁止使用现成智能体框架或编码智能体。

禁止白名单外模型、外部 API 与外网；官方控制台通信除外。禁止读取内部实现、探测隐藏真值、绕过计费或使用非白名单模型生成蒸馏数据；禁止使用现成的智能体框架和编码智能体：LangChain / LangGraph、AutoGen、CrewAI、AgentScope、Qwen-Agent、MetaGPT / OpenManus、CAMEL、smolagents，以及 Codex、Claude Code、Qwen Code、Kimi CLI 等

训练数据可来自六公开宇宙中的合法观测、自编模拟器和白名单模型输出。允许复用公开开发中的观测、候选规律及模型成果；正式测试仍新会话、独立配额与完整计分。改权重须保留训练配置、代码和数据生成脚本。

五 提交规范

攻坚组提交内容与文件边界

提交 agent/目录与 models.json 文件两类绝对路径。所有智能体、提示词、工具、配置及记忆均在 agent/内，由 run.py 统一启动。测评期间不得编辑本次代码、配置或权重。

材料	要求
agent/策略目录（可编辑）	可修改 run.py、models.py、tools.py 等策略文件，可新增子智能体、提示词、记忆及配置；agent/strategy.json 填写本组身份与版本
models.json（可编辑）	按唯一 id 逐项登记全部模型的白名单底座、权重 path 及可选 adapter_path。多份训练权重分别登记，权重本体保留原路径
官方固定文件（不可编辑）	rift/、rift_numerics/、development_worlds/、scripts/、shore_agent/及 docs/contracts/不得修改，包括积分、实验、计分及轮数设置
训练与复现材料	若修改权重，保留训练配置、代码及数据生成脚本，登记模型或适配器的实际路径

每个宇宙的自动交卷内容

每个宇宙自动产出配对的 law.py 与 claims.json。law.py 按公开接口 acceleration(t,bodies,params) 返回二维加速度，并携带本组已确定参数；指挥部调用固定积分器生成测试轨迹，不在隐藏测试上代拟合。程序须确定性、无外部读写或联网，可用 math、NumPy、SciPy。

奥卡姆约束：全局拟合参数 PARAMS 最多 5 个有限标量，不得用数组冒充单个参数。

claims.json 字段	填写内容
dynamics_order	JSON 整数 1 或 2：作用决定速度填 1，决定加速度填 2
hidden_matter	JSON 布尔值 true/false：是否存在位置不可见的作用源；可见天体源强未知不属于此项
time_dependence	JSON 布尔值 true/false：固定完整瞬时状态与属性后，作用是否显式随物理时间变化

time_dependence 表示显式时间依赖，普通轨道运动不属于此项。三项声明不改变统一加速度接口或积分器。

三项声明必须由白名单 LLM 依据观测自行判断并生成，禁止人工填写、改写或预置答案。三个字段均必填，不增加字段。格式示例（非真实答案）：
{"dynamics_order":1,"hidden_matter":false,"time_dependence":true}

六 计分规则

每个宇宙满分 100 分，由预言、定律和节约三部分组成。全部使用确定的程序规则评分，不使用 LLM 裁判，也不按自然语言解释的质量给分。

分项	满分	评分依据
预言分 P	80	预测轨迹与无观测噪声的隐藏验证轨迹之间的归一化误差
定律分 L	15	三个声明各 5 分；与预设真值一致得 5 分，否则得 0 分
节约分 C	5	仅当预言分 P≥40 时，按剩余能量比例计分；与定律分无关

预言分

使用预先固定的 N≥20 枚隐藏验证探针。各案例取 T 个等间隔相对采样点，投放时刻与跨度可不同。记预测位置为 p_{ik}、无噪真值为 q_{ik}，全部探针与时刻等权计算：

$$MSE = (1 / NT) \sum_i \sum_k \|p_{ik} - q_{ik}\|^2$$

范数平方为 x、y 两个坐标误差的平方和。令 $\bar{q}$ 为全部 NT 个真值位置的平均向量，定义归一化尺度：

$$V = (1 / NT) \sum_i \sum_k \|q_{ik} - \bar{q}\|^2, \quad e = MSE / max(V, 10^{-12})$$

$$P = 80 / (1 + 10e)$$

预言分连续下降、不分档：e=0 得 80 分，e=0.01 约 72.73 分，e=0.1 得 40 分，e=0.2 约 26.67 分；误差越大越接近 0。各组使用同一固定验证集，不按探索历史更换。

定律分与节约分

定律分按 LLM 自动生成的三个结构化字段逐项精确核对，不需要自然语言解释，不得人工填写或修改取值。每项正确得 5 分，合计最多 15 分，不另设自洽分。

令 E 为本宇宙实际消耗的能量，初始配额为 100 点。节约分规则为：

$$C = 5 \times (1 - E / 100) \ \text{当} P \geq 40\text{；否则} C = 0$$

节约分不计现实耗时、物理时间或免费 observe 剩余次数。P=40 且消耗 40 点时，C=3；P<40 时 C=0，即使定律满分也不例外。门槛判断和汇总使用未作显示舍入的分数。

总分与排名

$$\text{单宇宙得分} S = P + L + C$$

$$\text{最终成绩} = 0.3 \times \text{一级均分} + 0.4 \times \text{二级均分} + 0.3 \times \text{三级均分}$$

按加权均分排名。同分则比较各宇宙加权节约分，节约分低者排名靠前，仍相同则并列，不重跑模型或实验。

计费、计时以控制台为准。无效预测或候选超时使预言分为 0。

七 参考技术路线

可结合提示词与记忆管理、主动实验设计、数值拟合、符号回归及多次采样优化探索；也可对白名单模型进行量化、SFT 或 RL。以上技术仅作参考，具体方法使用由各攻坚组确定

指挥部特别声明

为了各攻坚组更好地完成任务，现做出如下声明：

1. 简单宇宙：

待探索宇宙中只包含力场作用，不受广义相对论，量子力学的影响，且考虑到各攻坚组成员知识背景不同，本次任务探索的宇宙不涉及复杂的力学、数学原理，仅涉及幂律、积分、梯度等基本数学知识，且均可由开源 LLM 自行处理，无需攻坚组成员自行计算；如使用非白名单模型或其 API 生成训练数据来蒸馏，或使用现成的智能体框架和编码智能体则会在赛后核查阶段被计为 0 分（详见"允许范围与边界”）。

2. 未知世界：

“此岸”即攻坚组所在宇宙的力场公式，如万有引力公式并不适用于待探索宇宙，但速度、加速度等基本物理量含义一致；

3. 基本规律：

在计分规则中，定律部分只需填写结构化文档中要求的三个部分，指挥部承诺不使用 LLM 裁判，不受到主观因素的影响（详见“计分规则”），且指挥部已事先进行实验，定律部分三条为较易判断的基本事实。

预祝各攻坚组取得好成绩！